LEGAL AGENT DATA DESIGN

用真实法律材料构造 Agent RL 训练任务

这份报告说明如何从 Harvey LAB 的任务类型出发，选择真实法律材料，整理跨文件证据，并生成可核对的评分标准。十道样本用于展示完整流程：先以 hint 或可复用的 skill 验证任务，再进行 no-hint DeepSeek Flash 评测。

法域：美国 · 数据包：selected10_flash_nohint_pass10_criterion80_90_v1 · 评测模型：DeepSeek Flash solver + judge

01 / DESIGN THESIS

我关注的问题：怎样构造可验证、能训练模型的法律任务

法律 RL 数据需要把工作请求、材料和评分标准对齐。任务要像律所收到的委托；关键结论要能从材料中推出；rubric 要说清每项要求依据什么。题目应接近目标模型的稳定能力边界：过于简单，训练信号有限；材料不足或答案无法判定，得到的只会是噪声。

> **设计原则**
> **构造模型在没有提示时可能漏掉的关键步骤，同时确保强模型能借助材料和适当指导完成任务，评分也能回到原文证据。**难度来自跨文件核对和连续判断；质量靠分层验证；扩量依赖自动检查。

从 LAB benchmark 看任务分布

本地固定快照包含 **2,010 个任务**：1,251 个专业领域任务，以及 contracts（498）、firm-knowledge（250）、diligence（11）三个跨领域集合。主要 operation 是 draft 568、knowledge retrieval 250、identify 211、review 179、compare 152、extract 151、redline 138、analyze 102、negotiate 94、escalate 87。这里有两个直接结论：**起草占比最高，但知识检索、合同谈判和升级处理合计也很大；任务长尾明显，不能只训练 draft 或 identify。**

2,010	24	30	12
LAB 任务快照	专业法律领域	观察到的 operation 标签	跨领域工作场景

我从 LAB 的任务分布建立 taxonomy，再按分工让不同 agent 处理材料：研究 agent 核验来源和版本，证据 agent 标注事实与出处，任务 agent 组织 query 和文件环境，rubric agent 把答案要求写成可判定的条目。构造阶段可以使用 hint 或 revise 来验证任务是否可解、找出设计问题；正式 no-hint 测评时，solver 只看到委托和材料。

这套分工保留两类信息：能核对的原文，以及会影响最终判断的关系。其余文件用于提供真实工作环境，也可能作为无关材料或反方材料。任务写法尽量接近日常法律工作，不在 query 里暴露评分要点。

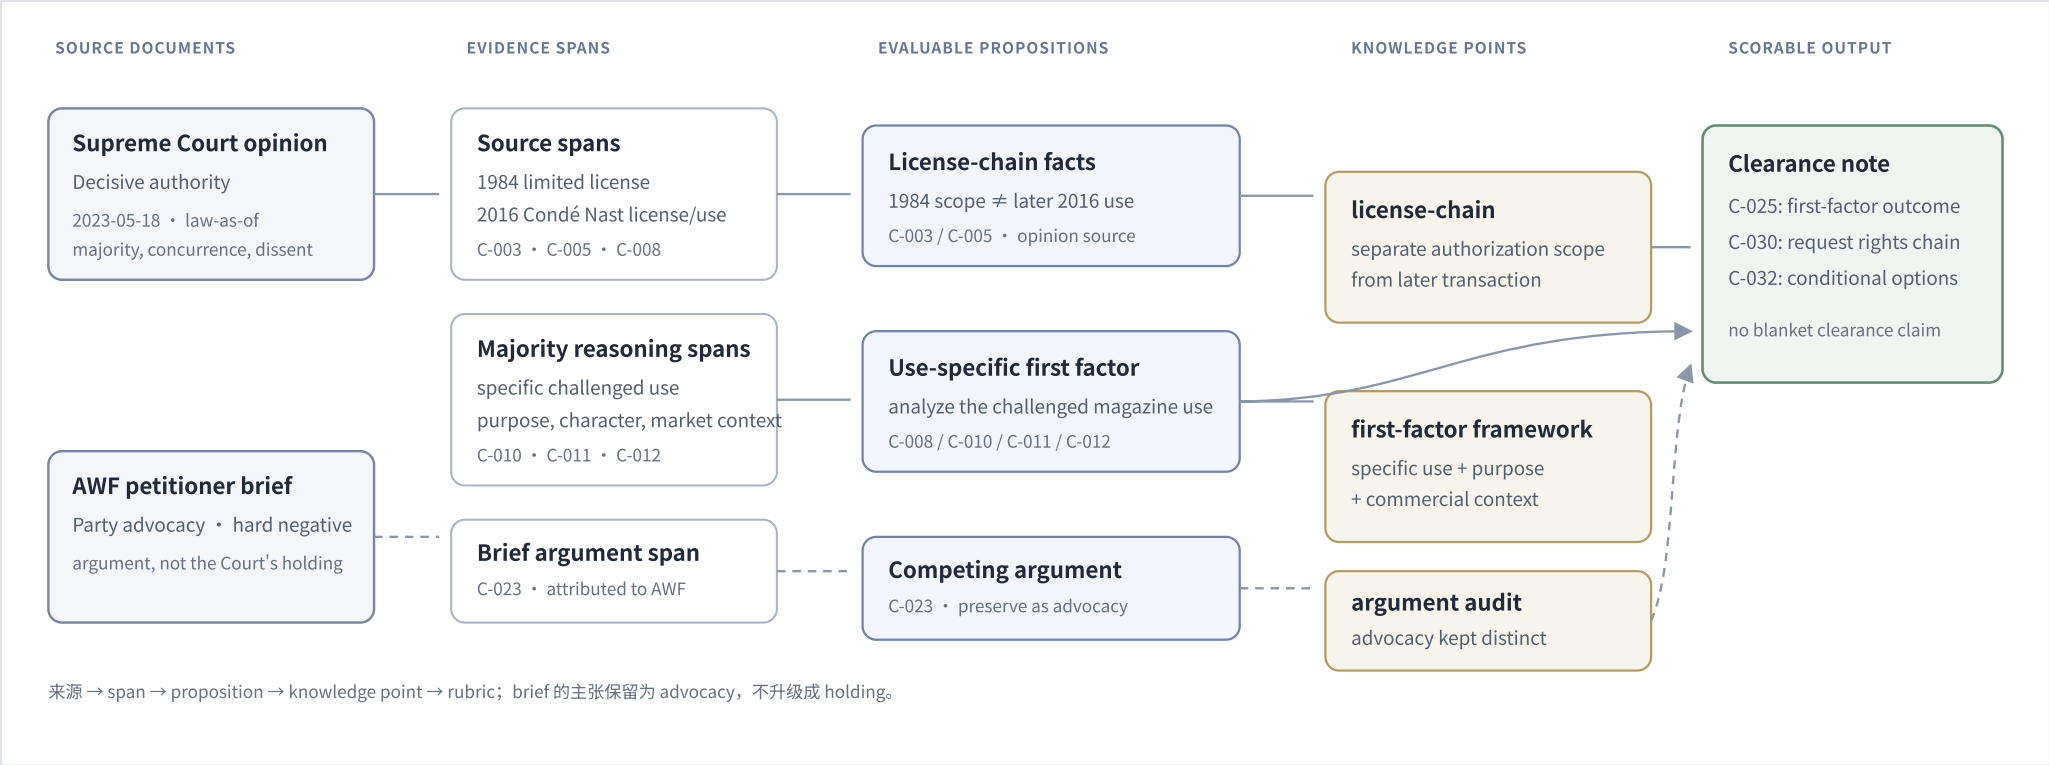
为什么需要图谱：把跨文件关系外部化

长上下文里同时塞进规则、事实、版本、主体和来源，要求模型靠一次性注意力记住它们之间的关系；上下文一长，关系容易丢失，模型也难以在多轮工作中追踪哪些判断已确认、哪些仍待核实。**证据图谱把这些关系显式存成可查询、可校验的结构：**DocumentVersion → EvidenceSpan → Entity/Fact → Rule/Condition → Proposition → Deliverable/Criterion。它既是构造系统的外部工作记忆，也是生成 hint、答案空间、rubric 和失败归因的共同底座。

> **评测边界：**图谱让跨文件的重要关系可被明确表示和校验；是否把图谱或其中的子图提供给被测 agent，是单独的任务设置。本批 10 题的 no-hint rollout 不向 solver 提供私有 evidence graph，图谱用于造题与评分溯源。后续可以另设 graph-enabled workspace 任务，衡量 agent 能否调用结构化状态，而不把它和本批 no-hint 成绩混在一起。

图谱案例：Warhol v. Goldsmith（B05）

用这道真实材料任务看一条图谱如何把不同文件压成可评分的交付：最高法院意见是决定性 authority；AWF 的 petitioner brief 只代表一方主张，不能当成法院 holding。两条来源路径在具体许可与使用事实处汇合，最后落到可追溯的 clearance note 要求。



示意依据 B05 的 private knowledge graph 与 rubric 路径整理；图谱状态标注为候选版本，独立模型核验待完成。这里展示的是"来源角色如何进入评分链"，不是把图示本身当作最终法律结论。

01

Legal work 是 all-pass 任务

法律交付通常是合取条件：期限、主体、适用规则、例外、引用和行动建议缺一项，都可能让整份交付物不可用。因此逐条通过率用于诊断，整题 all-pass 才接近“可以交给客户”。本批 297/337 条通过，但只有 1/10 整题全项通过，这两个数字必须一起看。

02

任务种类多，而且高度个性化

identify、extract、compare、draft、review 的认知路径不同；并购、破产、移民、税务和隐私的材料形态也不同。不能靠一套通用 prompt 批量改名。taxonomy 的作用是控制 operation、domain、交付物和法域的组合，并让每个组合有自己的材料依赖和验收方式。

03

难度来自跨文件、跨角色、跨时间的验证

真正的困难常在关系上：判决和 brief 谁是 authority；拟议规则与最终规则哪个适用；后续披露是否改变了前一文件的状态；同一主体在合同和公告中如何对应。把一份文件切成十份只是增加读取量，不会自动增加推理价值。

04

输出必须结构化、可解释、可溯源

结论要落到交付物结构里，并能回到具体来源、页码或条款。证据图把规则、适用条件、事实、来源 span、结论和 criterion 连起来，使 rubric 能自动生成，也使每个失败都能定位到知识、检索、推理或表达环节。

怎样把任务放在模型能力边缘

任务不靠冷僻法条或堆叠 rubric 来增加难度。关键答案需要模型完成多个真实判断：文件中的主体是否相同、哪个版本的规则适用、当事人主张和法院 holding 如何区分、事实是否满足规则条件，以及结论如何转成工作交付物。强模型可以借助材料和指导完成这些步骤；no-hint rollout 则可能在其中一两处出错。

为什么法律工作经常跨很多步骤

律师通常先确认主体和事项，再整理适用规则与时间线，之后把规则条件和事实逐项对照，标明缺失信息，形成结论，最后写进同一份交付物并补齐引用。**如果前面选错主体或规则版本，期限计算和后续建议都可能跟着出错；最终交付还要保证所有部分彼此一致。**

1 · State
实体表、authority set、时间线、open issues

→

2 · Transition
检索、消歧、版本覆盖、条件匹配

→

3 · Dependency
上游判断改变多个下游结论

→

4 · Delivery
结构、引用、行动一致

因此构造难度应看证据图的依赖深度、必须完成的状态转换和错误传播范围。单纯增加文件或把同一文件切碎，只增加 context length，不增加有效 horizon。

为什么需要多轮质量检查

RL 会反复使用评分信号，因此错误的材料、rubric 或 judge 结果会污染训练。每题要分别检查原文和版本、图谱关系、rubric 的可判定性、hint 是否泄漏答案、任务是否可解，以及空答是否会被误判。把检查拆开记录，出现问题时才知道应该回到哪一步修正。

Deterministic verify

hash、解析、source span、日期、计算、引用存在性

Independent model verify

hinted solve、逐项 judge、负例、失败归因、cross-judge

Batch verify

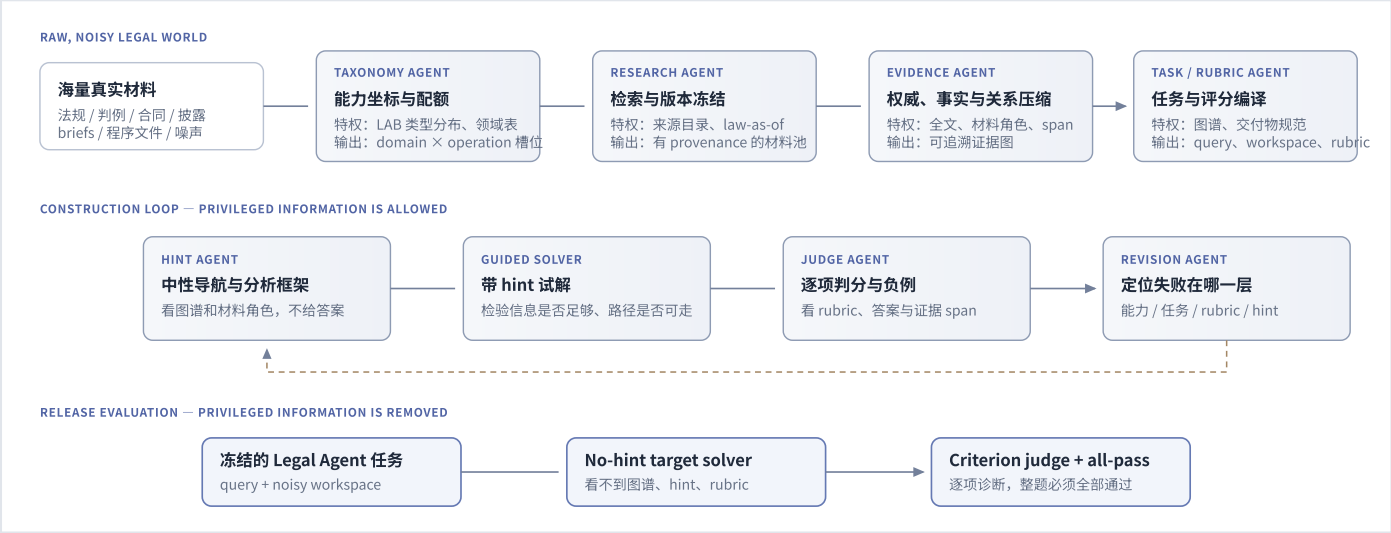
重复率、分布漂移、异常通过率、all-pass、版本 lineage

Human escalation

只处理抽样校准与 authority 冲突，保留原因供系统学习

Scale 的执行原则

确定性问题程序化，开放判断模型化，异常情况自动升级。人工不承担每题逐条复核，只处理小比例盲抽样和无法消解的 authority 冲突；每次人工结论都回写成规则、测试或 judge calibration，让新增数据不再带来线性增长的专家工时。



选中任务	Rubric criterion	No-hint 逐项通过	整题 all-pass
10	**337**	**297 / 337 · 88.13%**	**1 / 10**

02 / FULL TAXONOMY

完整种类设计：六个坐标共同定义一道题

taxonomy 的基准来自固定的 Harvey LAB 快照：2,010 个任务，包含 24 个专业法律领域，以及 contracts、diligence、firm-knowledge 三个跨领域集合。分类单位不是单一的“法律领域”，而是下面六个坐标的组合。只有组合在真实律所工作中成立，才进入造题队列。

法律领域	×	工作操作	×	任务场景	×	证据依赖	×	交

坐标	控制什么	为什么必须独立记录
A · Domain	实体法与业务语境	同为 draft，破产重整计划、H-1B checklist 和许可协议需要不同规则、材料和专业语言。
B · Operation	Agent 执行的动作	identify、extract、compare、draft、review、redline 等产生不同工作产品，不能只替换 query 动词。
C · Scenario	材料如何被使用	风险分析、核对、尽调、合规和诉辩各自有不同的输入结构与判分原则。
D · Evidence pattern	推理依赖与 long horizon	记录 authority 冲突、版本覆盖、实体消歧、条件/例外、计算、程序状态和缺失证据。
E · Deliverable	可交付成果的结构	memo、matrix、checklist、redline、filing、tracker、client update 对完整性和表达形式的要求不同。
F · Jurisdiction/time	法域、law-as-of 与材料版本	同一规则在不同法院、州、监管机关和生效日期下可能得出不同结论。

A · 24 个专业法律领域

这里展示完整 domain 目录及其在 LAB 固定快照中的题数。“本批”只表示这 10 道题是否覆盖该领域，不改变总体设计。

反垄断与竞争法 本批未覆盖
antitrust-competition
LAB 33 题

仲裁与国际争议解决 本批未覆盖
arbitration-international-dispute-resolution
LAB 37 题

银行与融资 本批 1 题
banking-finance
LAB 37 题

破产与重组 本批 1 题
bankruptcy-restructuring
LAB 36 题

资本市场 本批未覆盖
capital-markets
LAB 35 题

公司治理 本批 1 题
corporate-governance
LAB 97 题

公司并购 本批 1 题
corporate-ma
LAB 161 题

数据隐私与网络安全 本批未覆盖
data-privacy-cybersecurity
LAB 44 题

新兴企业与风险投资 本批未覆盖
emerging-companies-venture-capital
LAB 43 题

劳动与雇佣 本批未覆盖
employment-labor
LAB 39 题

能源与自然资源 本批未覆盖
energy-natural-resources

环境与ESG 本批未覆盖
environmental-esg

LAB 31 题

LAB 44 题

基金与资产管理 本批 1 题

funds-asset-management

LAB 66 题

医疗健康与生命科学 本批未覆盖

healthcare-life-sciences

LAB 43 题

移民法 本批 1 题

immigration

LAB 27 题

保险 本批 1 题

insurance

LAB 31 题

知识产权 本批 1 题

intellectual-property

LAB 147 题

国际贸易与制裁 本批未覆盖

international-trade-sanctions

LAB 41 题

诉讼与争议解决 本批未覆盖

litigation-dispute-resolution

LAB 52 题

房地产 本批未覆盖

real-estate

LAB 44 题

结构性融资与证券化 本批未覆盖

structured-finance-securitization

LAB 31 题

税法 本批 1 题

tax

LAB 34 题

信托、遗产与私人客户 本批未覆盖

trusts-estates-private-client

LAB 77 题

白领犯罪辩护与调查 本批未覆盖

white-collar-defense-investigations

LAB 21 题

> **三个跨领域集合：**`contracts` 498 题，覆盖 draft / review / redline / negotiate / escalate；`diligence` 11 题，是跨业务的数据室审查工作流；`firm-knowledge` 250 题，要求跨事项检索内部先例。后两类尤其依赖连贯 workspace，不能用一份公开法规替代。

B · 工作操作：10 个主要类别 + 20 个长尾类别

`work_type` 与 operation 分开记录。LAB 原始 work_type 只有 analyze、draft、review、research，且 748 题缺失；operation 根据任务实际动作进一步细分。扩量时按 2,010 题的 operation 边际与 domain × operation 联合分布取样。

主要操作	LAB 题数	每千题目标	典型交付物与验收重点
起草 `draft`	568	283	可直接审阅的 memo、filing、agreement、policy
知识检索 `knowledge_retrieval`	250	124	相关先例、范围限制与适配后的工作产品

主要操作	LAB 题数	每干题目标	典型交付物与验收重点
识别 identify	211	105	issue/risk register，含来源、后果和行动
审查 review	179	89	逐项缺口、准确性或合规审查
比较 compare	152	76	双边/多版本差异矩阵与控制版本
抽取 extract	151	75	结构化字段、条款、日期、例外和来源 span
红线修改 redline	138	69	修改文本、issue list 与修改理由
分析 analyze	102	51	规则—事实—结论 memo 与不确定性
谈判 negotiate	94	47	立场、fallback、升级点和谈判记录
升级处理 escalate	87	43	超 playbook 风险、决策人和待批准事项

长尾操作保留原标签，不强行吞并，以免丢失任务形态：

assess 22 · **research** 10 · **summarize** 8 · **triage** 8 · **build** 5 · **map** 5 · **prepare** 4 · **audit** 2 · **respond** 2 · **synthesize** 2 · **categorize** 1 · **complete** 1 · **conduct** 1 · **conform** 1 · **flag** 1 · **generate** 1 · **markup** 1 · **track** 1 · **update** 1 · **verify** 1

C · 12 个任务场景

Scenario 描述"材料如何进入工作过程"。一个任务可绑定多个 scenario，例如隐私事件题可以同时属于 regulatory-compliance、validation-reconciliation 和 calculation-timelines。

risk-analysis

风险识别

从触发事实到法律后果、置信度和下一步；同时惩罚 false positive。

validation-reconciliation

校验与核对

在版本、数字、日期和控制来源之间找差异并确定应修正项。

structured-extraction

结构化抽取

抽取实体、条款、例外、日期和 source span，显式标记缺失字段。

transaction-drafting

交易文件起草

把 term、precedent 与客户立场编成定义一致、产生预期法律效果的文本。

dispute-submissions

诉辩与监管回应

结合程序阶段、记录与 adverse authority 形成 motion、brief、response 或 filing。

legal-research

法律研究

限定法域和时间，检索 holding、例外与相反权威，给出可执行结论。

due-diligence

尽职调查

形成有优先级的发现、材料缺口和针对性的补充请求。

regulatory-compliance

监管合规

做 applicability—obligation—evidence—gap—remediation 矩阵。

calculation-timelines

计算与期限

依控制公式和触发日计算金额、waterfall、deadline 或 calendar。

contract-redline

合同审改与谈判

依据 playbook 修改条款，处理联动定义、fallback 和 escalation。

knowledge-retrieval

律所知识复用

在异构先例库中找真正相关且未过时的材料，再适配当前事项。

matter-synthesis

事项综合

维护事实图和时间线，将多文件中支持的结论、未决问题与行动整合。

D–F · 证据依赖、交付物与法域时点

Evidence pattern / long horizon

- authority hierarchy：holding、brief、agency guidance 和合同的效力不同；
- version chain：proposal、final rule、amendment、vacatur、rescission；
- entity resolution：同一主体、关联方、合同角色和文件别名；
- condition & exception：规则只有在事实触发后才适用；
- calculation & timeline：金额、期限和程序节点依赖前序分类；
- missing/open facts：结论需要明确保留，而不是猜测。

Deliverable family

- memo / advice letter / client update；
- issue register / risk register / open-items list；
- comparison matrix / extraction schedule / worksheet；
- checklist / calendar / tracker；
- agreement / policy / filing / response draft；
- redline / markup / negotiation fallback table；
- research note / authority survey / precedent retrieval。

真实材料从哪里来

来源按"权威原文 → 事项事实 → 标注语料"分层。发现语料可以帮助找到合同或条款，最终 rubric 的法律命题仍需回到可核验原文。

来源层	具体来源	在流水线中的用途
成文法与行政规则	eCFR、U.S. Code / OLRC、Federal Register 与 GovInfo	冻结法规版本、生效时间、定义、义务、例外和后续修订。
判例与诉讼材料	CourtListener / Free Law Project、法院官方意见和案卷、美国最高法院 opinions 与 briefs	取得 holding、程序状态、相反意见和当事人主张；brief 只作为 advocacy。
监管与政府材料	SEC、FTC、FDIC、DHS/USCIS 等机构的 orders、complaints、releases、rulemaking records	确定监管立场、交易事实、执行状态与官方时间线。
交易与公司文件	SEC EDGAR 原始 filings/contracts；KL3M EDGAR 用于发现合同与建立检索池	构造真实 agreement、amendment、proxy、10-K/8-K 与披露之间的交叉核对。
条款与任务语料	Atticus CUAD、ACORD、MAUD	学习条款类型、问法和任务 schema；追溯原始合同后才可作为证据，不把数据集标签当法律权威。

当前法域范围以美国为主，后续可为英国/欧盟另建版本快照。中国内地与香港分支按此前决定暂不进入本轮 taxonomy。

这 10 题实际落到的来源

> **交易与监管：**B01 使用 Microsoft–Activision 的交易记录与公司年报；B02 使用 FDIC purchase-and-assumption agreement 及 FDIC/First Citizens/Signature 公告；B03 使用 Tesla 2024 proxy 与季度更新。
>
> **判例与案卷：**B04、B05、B09、B10 使用美国最高法院意见并配套双方 briefs，保留 certificate/word-count 等自然外围材料。
>
> **规则版本：**B06 使用第五巡回法院意见、原始 Federal Register final rule 和 2024 后续技术文本；B07 同时提供 2023 proposed rule 与 2024 final rules。
>
> **隐私监管：**H-FUSION-01 使用 FTC BetterHelp complaint/order/consent/public-comment analysis，并通过 source notes 连接 eCFR 16 CFR Part 318、42 U.S.C. §17937、GovInfo Federal Register 和 FTC enforcement materials。

一个简单的假设例子：供应商数据事件响应

分类坐标

Domain：data-privacy-cybersecurity
Operation：review
Scenarios：regulatory-compliance + validation-reconciliation + calculation-timelines
Deliverable：incident-deadline-matrix.docx

自然 query

> Review the DPA, incident notice, system log, and applicable breach rules. Prepare a cited deadline matrix identifying responsible parties, notice triggers, open facts, and next steps.

材料包：执行版 DPA、供应商事件通知、访问日志、适用规则的冻结版本，以及一份只谈一般安全能力的营销白皮书。白皮书是合理外围材料，不能证明本次事件已经采取了某项控制。

Long-horizon 路径：先对齐控制者/处理者与合同角色 → 从日志确定发现时间和数据类型 → 判断通知规则是否被触发 → 将法定期限与合同 24 小时义务分别计算 → 登记缺失的受影响人数/州别 → 生成 deadline matrix，并让每个结论回到条款、日志或法规。

可评分 rubric 示例：区分合同通知义务和法定义务；使用正确的触发日；不把营销白皮书当作已实施控制；将缺失事实列为 open item；给每个 deadline 标明来源；行动顺序与计算结果一致。这个例子只解释分类和造题方式，不计入本批十题及其准确率。

本批 10 题在完整 taxonomy 中的位置

Operation 覆盖

Operation	本批题数
compare	1
draft	5
extract	1
identify	2
review	1

覆盖边界

本批覆盖 10 个专业领域与 5 类 operation，主要验证跨文件、版本和 authority 对齐。它没有覆盖 contracts 的 redline/negotiate/escalate，也没有覆盖 firm-knowledge、diligence 和多数长尾 operation。因此十题分布只是一次选题结果，不代表完整训练配额。

---

03 / END-TO-END PIPELINE

数据构造与评测流程

流程分为五段：确定任务类型，核验并整理材料，构建证据关系，写 query 和 rubric，用指导式 rollout 检查后再做 no-hint 评测。各阶段保存中间产物，出现问题时回到对应步骤修订。

A	B	C	D	E
任务类型	**材料与证据**	**任务与评分**	**指导式验证**	**正式评测**
LAB taxonomy	real docs → graph	query + workspace + rubric	solve → judge → revise	freeze → no-hint score

步骤	负责 Agent 与特权信息	具体操作	产物与门槛
1. LAB 能力拆解	Taxonomy agent 看 LAB 任务目录、operation 分布和律所工作类型。	把 benchmark 拆成 domain × operation × deliverable × evidence pattern。区分 identify、extract、compare、draft、review 等不同工作路径。	能力树和目标配额。每个槽位必须对应真实律师工作，不能只是法律知识问答。
2. 选知识点	Legal-domain agent 看权威规则目录、判例主题和 law-as-of。	列规则、要件、例外、程序状态、期限和可能改变结论的事实。先设计"需要做什么判断"，再找材料。	知识点卡片：法域、时间截点、主体、争点、潜在分支和目标交付物。
3. 建真实材料池	Research agent 能访问 eCFR、U.S. Code、CourtListener、EDGAR、真实合同和官方案件记录。	下载原始文档，保存 URL、发布日期/生效日、抓取时间、hash、页数和版本；与 LAB 材料做路径/hash 排重。	冻结 source bundle。来源不可验证、版本不明或关键文件缺失则拒收。
4. 标材料角色	Source-role agent 看全文和 authority 层级。	将文件标成 decisive、corroborating、context、hard negative、irrelevant 或 mixed。识别 opinion/brief、proposal/final rule、executed contract/announcement 的不同法律地位。	`material-roles.json`。例如 B05 中判决是 decisive，petitioner brief 是 hard negative，word-count 和 service certificate 是合理噪声。
5. 建证据图	Evidence agent 看全文、材料角色和精确 source span。	建立 DocumentVersion → EvidenceSpan → EvaluableProposition → KnowledgePoint 关系；再加实体、时间、条件、例外和依赖边。	`knowledge-graph.json`/`evidence-graph.json`。每个可评分命题至少有一个有效 span。
6. 增加非线性	Task designer 看图谱，但不直接复制答案。	让关键结论依赖多个关系：跨文件实体对齐、后续文件改变状态、规则条件与案情事实匹配、authority 冲突、行动依赖。加入真实外围材料和可辨认 hard negative。	依赖图。删除任一决定性材料后，至少一项关键结论应变得无法可靠回答；纯拆文件和纯加长度不算。

步骤	负责 Agent 与特权信息	具体操作	产物与门槛
7. 写自然 query 与 workspace	Task-writing agent 看 taxonomy 槽位、交付物和图谱摘要。	用律师交办口吻写短 query，说明动作、对象、时间和交付物，不枚举 rubric。把关键事实留在材料中。	`task.json` 与 documents。query 保持简洁，关键法律细节由 workspace 材料承载。
8. 编译答案空间与 rubric	Rubric agent 看证据图、交付物规范和来源 span。	每个 proposition 编成一个原子 criterion，写 pass/fail、等价表达、证据定位和影响的交付物部分。风格偏好与事实/法律正确性分开。	`rubric.json`。无证据、复合要求、重复、方向含糊或只考边角信息的 criterion 退回。
9. 生成 hint / skill	Hint agent 看图谱、材料角色与方法框架，但不看/不输出金标准答案。强模型可从多次 rollout 中归纳可复用的 skill 或 experience，作为逐题 hint 的替代形式。	生成 source-navigation 和 methodology guidance：优先文件/章节、authority 顺序、时间线、实体消歧、proposal/final、holding/advocacy、引用和未决事实要求。经验条目需保留适用条件与来源范围。	`solver-hints.json` 或版本化 skill/experience 库；记录生成模型、任务覆盖、law-as-of、graph 版本与来源，不能复制 rubric 原句或直接给结论。
10. Hinted rollout	可由强模型直接执行 guided rollout；输入 query、workspace 与 hint/skill，不看 rubric/答案。	强模型完成真实交付物并检查可解性、缺文件、错误版本、query 歧义和不可判定 criterion；归因后由强模型提出 revise，再重跑和复判。	rollout、skill/hint 版本与模型/prompt 元数据。finish_reason 非 stop、引用不存在或输出截断，直接失败。
11. Judge 与负例	Judge 看冻结 rubric、answer 和相关证据 span；最好与 solver 独立。	逐 criterion 判 pass/fail，检查 unsupported claim；用空答/无实质分析做 negative control，确保 judge 不会仅因看到材料就给分。	criterion verdict、理由、negative-control 结果。只保存总分不够，因为后续 revise 需要失败位置。
12. 四路失败归因	Revision agent 同时看 answer、hint、task、rubric、材料和 judge 理由。	每个失败只能先归到 agent capability、task design、rubric quality 或 hint quality，再提出修改。低分本身不是删 rubric 的理由。	`revision-report.json`：根因、证据、修改对象、old/new 值。能力失败不修改题目，保留为训练信号。

步骤	负责 Agent 与特权信息	具体操作	产物与门槛
13. 带 hint revise	相应 specialist 只修改被归因的层。	Hint 问题补中性导航或去泄漏；task 问题改 query/补真实材料并更新图；rubric 问题改边界、拆复合项或修 span；随后用 v1 hint 重跑、重判。	版本化 diff + hinted answer v1 + verdict v1。不能拿 v0 的 judge 结果给 v1 评分，也不能单纯以涨分为验收标准。
14. 质量门与冻结	Gate agent 读取全部 provenance、hash、版本和测试结果。	检查材料可读、图谱连接、criterion 锚点、hint 无答案泄漏、负例零分、答卷完整、修改理由成立。失败继续回到 11–13。	冻结 release candidate：query/docs/graph/rubric/hint 和所有 hash。构造期 hint 不进入最终 solver。
15. No-hint 正式评测	Target solver 只看 query 和真实 workspace；final judge 在答卷冻结后看 criterion。	按 LAB 风格完成任务并逐条判分，报告 pooled criterion rate 和 task all-pass。再按错误类型、难度和 taxonomy 配额选入 RL 数据。	本批口径：297/337（88.13%）逐项通过，1/10 all-pass。它不是 hinted rollout 成绩。

多次 verify 怎样串进生产线

验证点	自动检查	失败后回到哪里
V1 · Source verify	URL/文件可读、hash、发布日期与生效日、版本重复、LAB 材料排除、authority 类型。	回到材料采集；缺关键原文则拒收。
V2 · Graph verify	每个 proposition 有 source span；实体、版本、条件和例外边连通；删除 decisive source 的反事实测试。	回到证据图或材料角色标注。
V3 · Rubric verify	原子性、可观察 pass/fail、无重复、source span 有效、负例不通过、要求没有超出材料。	回到 rubric compiler；不能因模型低分直接删项。
V4 · Solvability verify	强模型带 hint 完整作答，或使用其 rollout 归纳的 skill/experience 执行；检查 finish_reason、引用、交付物结构和 unsupported claim。	四路归因后只修改 task、rubric、hint 或 skill 的问题层。
V5 · Judge verify	空答/无实质分析 negative control、重复判分一致性、必要时独立模型 cross-judge。	校准 judge prompt、criterion 边界或模型组合。

验证点	自动检查	失败后回到哪里
V6 · Release verify	冻结 hash 后 no-hint 重跑；检查 pooled rate、all-pass、异常模式、taxonomy 配额和 family 泄漏。	拒收、回流或进入 RL 数据；版本变化必须重新评测。

> **自动化原则：**确定性问题优先用程序校验，开放判断由相互独立的 solver / judge / revision agents 处理，批量异常由统计规则发现。人工只接收带完整证据包的升级项和小比例盲抽样。这样每新增一批数据不会线性增加专家工时。

一个具体 revise 例子：B06 私募基金规则

如果 hinted answer 把 SEC 旧最终规则一概写成仍然有效，revision agent 先看 hint 是否已经要求按第五巡回法院 disposition 与后续 Federal Register 文本排序。提示充分，则归为 agent capability：保留 task 和 rubric。若 hint 只列了法规名却没有提示版本顺序，则修改 hint 为"先读判决 disposition，再读后续技术性文本，最后逐项回查原规则"，然后重跑。若某个 criterion 声称"全部义务均失效"，但证据只支持部分规则变化，则归为 rubric quality，修 criterion 和 source span。修订版本通过 hinted gate 后，仍要重新跑 no-hint，确认模型必须自己完成时间与 authority 对齐。

> **事实边界：**这 10 题的私有目录包含 hint 资产，但选题 manifest 的正式成绩标为 `hint_type=none`。现有记录不足以证明每题都完整跑过 hinted revise，所以这里把它写成统一生产流程，不把未执行的步骤伪装成当前 worklog。

证据图如何落到评分



criterion 必须可以从答案回溯到证据锚点，并从证据锚点回到权威来源和适用条件。

一条 criterion 应能从答案中的主张回到 EvaluableProposition，再回到 EvidenceSpan 和 DocumentVersion。图谱同时保留法域、时间版本和材料角色，因此 judge 可以区分"模型没写到"和"这个要求本身没有证据"。

---

04 / SELECTED TASKS

十题在工作流中的具体落点

题目按用户给出的顺序排列。每题的时间截点、原始 query、交付物、真实材料角色、rubric 覆盖主题和证据图谱规模均从所给文件夹读取。展开条目可进入原始 task、rubric、知识图谱和选题评分文件。

ID / 任务	Operation	任务类型	Rubric 通过	完成度	通过率
B02-svb-assumption	Extract SVB transfer and assumption terms	抽取	34/34		100.0%
B01-microsoft-activision	Identify Activision closing issues	识别	30/36		83.3%
B03-tesla-conversion	Compare Tesla conversion rights	比较	30/32		93.8%
B04-purdue-release	Draft Purdue creditor update	起草	31/32		96.9%
B05-warhol-license	Draft Warhol licensing clearance note	起草	29/32		90.6%
B06-private-fund-rules	Review private-fund rule tracker	审查	30/32		93.8%
B07-h1b-modernization	Draft H-1B filing checklist	起草	34/36		94.4%
B09-moore-attribution	Draft Moore refund advice letter	起草	30/32		93.8%
B10-great-lakes-policy	Identify Great Lakes coverage open items	识别	26/32		81.2%
H-FUSION-01	Telehealth Ad-Tech Data Sharing: HBNR Notification and FTC Section 5 Response Plan	起草	23/39		59.0%

B02-svb-assumption	**Extract SVB transfer and assumption terms**	抽取 · 34/34
B01-microsoft-activision	**Identify Activision closing issues**	识别 · 30/36
B03-tesla-conversion	**Compare Tesla conversion rights**	比较 · 30/32
B04-purdue-release	**Draft Purdue creditor update**	起草 · 31/32
B05-warhol-license	**Draft Warhol licensing clearance note**	起草 · 29/32
B06-private-fund-rules	**Review private-fund rule tracker**	审查 · 30/32
B07-h1b-modernization	**Draft H-1B filing checklist**	起草 · 34/36
B09-moore-attribution	**Draft Moore refund advice letter**	起草 · 30/32
B10-great-lakes-policy	**Identify Great Lakes coverage open items**	识别 · 26/32

05 / EVALUATION

DeepSeek Flash：局部完成度较高，整题稳定性仍有限

在这 10 道题、337 条 criterion 上，Flash 通过 297 条（88.13%）；B02 SVB 全项通过，H-FUSION-01 为 23/39（58.97%）。这显示它能处理不少局部法律分析与交付要求，但跨文件关系、规则状态和细粒度标准叠加时，尚不能稳定完成整题。

表现较好的部分

逐项通过率处于较高区间，说明模型能从真实材料中提取事实、识别部分规则与主体关系，并完成多种常见法律工作交付。较高的局部得分适合作为错误定位信号。

当前短板

只有 1/10 题全项通过，局部答对尚未转化为整份交付物的可靠性。复杂跨文件对齐、权威与版本排序、边界条件覆盖仍容易漏项。

上述数字是本批 no-hint rollout 的 criterion 统计，不是法律结论的独立认证。后续应重点审计 rubric 证据可信度，并用重复 rollout、独立 judge 与必要的反例控制检验评测稳定性。

NEXT ITERATION

下一轮优先事项

1 · Rubric 可信度审计

逐条核对 criterion 是否原子、可观察、能由权威材料定位，并准确表达适用条件、版本与法律效果。加入独立来源复核、等价答案测试、空答/反例控制和跨 judge 一致性检查；删除无法被证据支持、对交付没有实质影响或只是为了压分的标准。

2 · 任务类型均衡

按 LAB 的 operation 与 domain 联合分布制定扩量配额，避免被少数高频类型或本次十题的筛选结果带偏。逐步补足 draft、knowledge retrieval、identify、review、compare、extract、redline、analyze、negotiate、escalate，并覆盖 diligence、firm-knowledge 与长尾操作。

3 · 法律体系扩展

先把美国联邦与州法边界、州际差异和 authority hierarchy 做扎实，再建立英国与欧盟独立分支。每个新法域使用自己的官方来源、规则版本、术语映射和证据图谱；不把美国规则直接移植为通用标准。

4 · 跨文件与 long-horizon 验证

测量结论所需的证据依赖深度、实体消歧、状态转换、期限计算和下游传播。通过移除决定性材料、替换版本或扰动关键事实验证任务确实需要关系推理；图谱作为 solver workspace 的任务单列评估。

5 · 扩量自动化

把来源与版本、图谱连通、rubric 锚点、负例、重复判分、hint 泄漏、分布漂移和 release hash 纳入可重复的自动 gate。独立模型负责开放式复核；人工仅抽查小比例样本和处理无法自动消解的权威冲突。